

LAB 02 - WPROWADZENIE DO GŁĘBOKIEGO UCZENIA - CNN

Karol Działowski

nr albumu: 39259
przedmiot: Uczenie Maszynowe 2

Szczecin, 12 stycznia 2021

Spis treści

| | |
|---|----------|
| 1 Cel laboratorium | 1 |
| 2 Wyniki eksperymentu dla 100 epok | 2 |
| 2.1 Porównanie architektur | 2 |
| 2.2 Krok uczenia | 3 |
| 2.3 Wnioski | 3 |
| 3 Wpływ liczby epok na jakość modelu | 3 |
| 3.1 Wnioski | 5 |
| 4 Sprawdzenie działania klasyfikatora przy uwzględnianiu zniekształceń | 5 |
| 4.1 Wnioski | 7 |

1 Cel laboratorium

Celem laboratorium było zapoznanie się z funkcjonalnością pakietów *TensorFlow* i *Keras*. W tym celu zaimplementowano prosty model sieci splotowej. Przetestowano trzy architektury:

1. Sieć z jedną warstwą splotową z 128 filtrami
2. Sieć z dwoma warstwami splotowymi z odpowiednio (64, 32) filtrami
3. Sieć z trzema warstwami splotowymi z odpowiednio (32, 16, 8) filtrami

Sterując parametrami:

- liczba epok uczenia
- krok uczenia

Wyżej wymienione parametry przetestowano opierając się o funkcję kosztu (*loss*) i dokładność (*accuracy*).

2 Wyniki eksperymentu dla 100 epok

W poniższej tabeli przedstawiono przetestowane modele posortowane względem dokładności.

| Architektura | Krok uczenia | Funkcja kosztu | Dokładność |
|--------------|--------------|----------------|------------|
| 2 | 0.02 | 0.034082 | 0.9891 |
| 2 | 0.05 | 0.032457 | 0.9888 |
| 2 | 0.10 | 0.037297 | 0.9880 |
| 2 | 0.01 | 0.038692 | 0.9875 |
| 1 | 0.05 | 0.048290 | 0.9850 |
| 1 | 0.10 | 0.052027 | 0.9839 |
| 1 | 0.02 | 0.049847 | 0.9838 |
| 1 | 0.01 | 0.055686 | 0.9832 |
| 3 | 0.02 | 0.086412 | 0.9742 |
| 3 | 0.10 | 0.105296 | 0.9696 |
| 3 | 0.05 | 0.114323 | 0.9662 |
| 3 | 0.01 | 0.216589 | 0.9358 |

Tabela 1: Przetestowane modele dla 100 epok

2.1 Porównanie architektur

| Architektura | Funkcja kosztu | Dokładność |
|--------------|----------------|------------|
| 2 | 0.035632 | 0.988350 |
| 1 | 0.051463 | 0.983975 |
| 3 | 0.130655 | 0.961450 |

Tabela 2: Średnia jakość modelu ze względu na rodzaj architektury dla 100 epok

2.2 Krok uczenia

| Krok uczenia | Funkcja kosztu | Dokładność |
|--------------|----------------|------------|
| 0.02 | 0.056780 | 0.982367 |
| 0.10 | 0.064873 | 0.980500 |
| 0.05 | 0.065023 | 0.980000 |
| 0.01 | 0.103656 | 0.968833 |

Tabela 3: Średnia jakość modelu ze względu na kroku uczenia dla 100 epok

2.3 Wnioski

Najlepszym modelem okazała się sieć z dwoma warstwami splotowymi osiągając dokładność 98.9% dla kroku uczeniu 0.02 i 100 epok. Najgorsze wyniki osiągała architektura składająca się z trzech warstw splotowych.

Nie zauważono wpływu kroku uczenia na uzyskane wyniki dla 100 epok podobnie jak w modelach MLP.

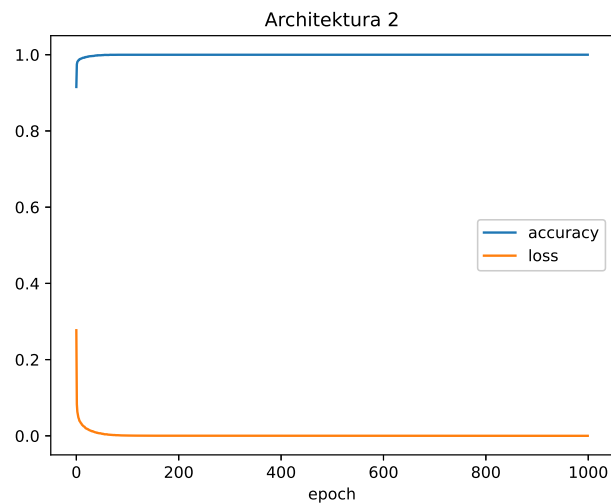
3 Wpływ liczby epok na jakość modelu

Przetestowano dokładność modelu na zbiorze testowym dla architektury z dwoma warstwami splotowymi. Wyniki przedstawiono na rysunku 1.

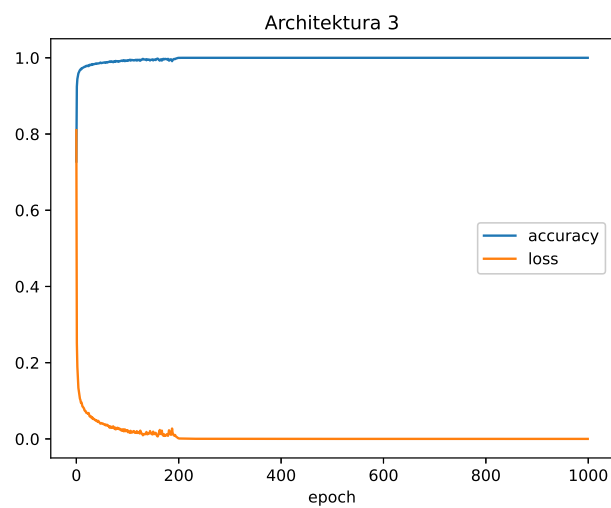


Rysunek 1: Dokładność i funkcja kosztu danych testowych modelu dla architektury 2

Zbadano wpływ liczby epok na proces uczenia modelu dla wybranych modeli. Przetestowano trzy architektury z krokiem uczenia 0.02 i zapisano dokładność i funkcję kosztu na zbiorze uczącym dla kolejnych epok.



Rysunek 2: Dokładność i funkcja kosztu na danych uczących modelu dla architektury 2 w procesie uczenie



Rysunek 3: Dokładność i funkcja kosztu na danych uczących modelu dla architektury 3 w procesie uczenie

| Architektura | Funkcja kosztu | Dokładność |
|--------------|----------------|------------|
| 1 | 0.0772 | 0.9844 |
| 2 | 0.0852 | 0.9883 |
| 3 | 0.306 | 0.9761 |

Tabela 4: Dokładność i funkcja kosztu po 1000 epokach.

3.1 Wnioski


Liczba epok ma istotny wpływ na dokładność klasyfikatora, pokazuje to rysunek [1](#). Nauczane modele na 1000 epokach dawały lepsze wyniki od modeli nauczonych tylko przy 100 epokach. Ostateczny ranking pozostał bez zmian, najlepszym modelem była sieć z dwoma warstwami splotowymi.

4 Sprawdzenie działania klasyfikatora przy uwzględnianiu zniekształceń

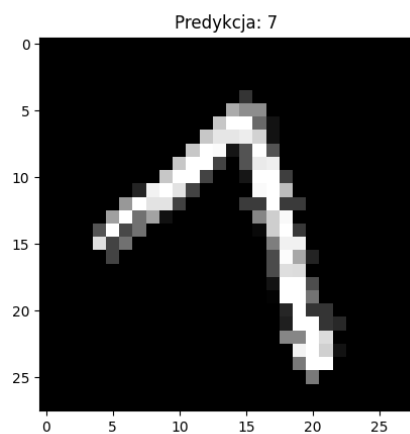
Powyższe testy przeprowadzono na najlepszym modelu architektury 2 z krokiem uczenia 0.02 uczonym przez 1000 epok.

Przetestowano klasyfikator na testowym obrazie dokonując następujących zniekształceń:

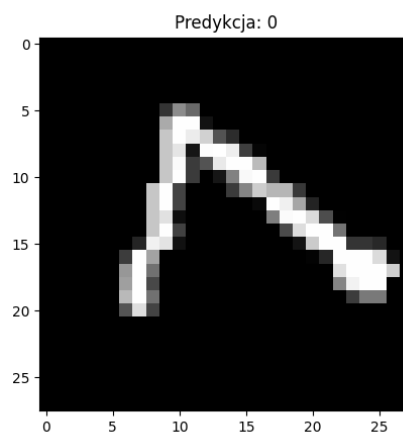
- cyklicznego przesunięcia obiektu
- rotacji obiektu
- dodania szumu



Rysunek 4: Obraz oryginalny




Rotacja 45 stopni




Rotacja 80 stopni

Rysunek 5: Wpływ rotacji na predykcje




Przesunięcie 2 piksele w osi X




Przesunięcie 5 pikseli w osi X

Rysunek 6: Wpływ cyklicznego przesunięcia na predykcje



Dodanie szumu od 0 do 120



Dodanie szumu od 0 do 160

Rysunek 7: Wpływ szumu na predykcje

4.1 Wnioski

Testowany klasyfikator radzi sobie lepiej z rotacjami względem MLP potrafiąc rozpoznawać badany obraz do rotacji 45 stopni gdzie MLP dawał fałszywe wyniki już przy rotacji 25 stopni.

Dokładność obrazów względem przesunięć jest analogiczna jak w przypadku MLP. Czyli przesuając obraz od ponad 2 piksele otrzymujemy fałszywe wyniki.

Klasyfikator radzi sobie bardzo dobrze z szumem. Przedstawia to obraz 7 gdzie dodając szum o maksymalnej wartości 120 klasyfikator daje jeszcze poprawne wyniki przy dużym zniekształceniu obrazu.

Podsumowując, sieci splotowe osiągają lepsze wyniki od sieci MLP dla badanego problemu. Kosztem tego jest czas uczenia, który bez wspomagania kartą graficzną jest dużo większy niż w przypadku uczenia sieci MLP.